



UNIVERSIDAD DE CHILE
FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS
DEPARTAMENTO DE INGENIERÍA MECÁNICA

**IMPLEMENTACIÓN DE ALGORITMOS DE RECONOCIMIENTO DE
OBJETOS PARA LA IDENTIFICACIÓN DE FALLAS EN CORREAS
TRANSPORTADORAS**

MEMORIA DE TÍTULO PARA OPTAR AL TÍTULO DE INGENIERO CIVIL MECÁNICO

FERNANDO IGNACIO NAVARRETE URRUTIA

PROFESOR GUÍA:
VIVIANA MERUANE NARANJO

PROFESOR CO-GUÍA:
HAROLD VALENZUELA COLOMA

SANTIAGO DE CHILE
2025

RESUMEN EJECUTIVO DEL INFORME FINAL
PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL MECÁNICO
POR: FERNANDO IGNACIO NAVARRETE URRUTIA
FECHA: 2025
PROF. GUÍA: VIVIANA MERUANE NARANJO
PROF. CO-GUÍA: HAROLD VALENZUELA COLOMA

IMPLEMENTACIÓN DE ALGORITMOS DE RECONOCIMIENTO DE OBJETOS PARA LA IDENTIFICACIÓN DE FALLAS EN CORREAS TRANSPORTADORAS

La detección temprana de fallas en correas transportadoras es fundamental para evitar paradas no programadas y pérdidas operativas en industrias críticas. Los métodos tradicionales basados en inspección visual presentan limitaciones en velocidad, costo y precisión. En contraste, las técnicas de inteligencia artificial, especialmente aquellas basadas en redes neuronales convolucionales (CNN) y arquitecturas Transformer, ofrecen soluciones automatizadas y escalables para la clasificación de fallas mediante visión computacional, favoreciendo el mantenimiento predictivo y la supervisión continua.

Este trabajo de memoria de título se enfoca en desarrollar un sistema de detección de fallas en correas transportadoras mediante técnicas de visión computacional y aprendizaje profundo. El objetivo general de este trabajo es implementar y evaluar algoritmos de detección de objetos, basados en inteligencia artificial. Entre los objetivos específicos destacan el entrenamiento de algoritmos con bases de datos etiquetadas, la programación de modelos CNN como YOLO y SSD, la implementación de modelos Transformer como DETR y DINO, el ajuste de hiperparámetros para optimizar desempeño, y la evaluación comparativa mediante métricas estándar de visión por computadora.

La metodología contempla la implementación y entrenamiento de modelos en entornos especializados, utilizando bases de datos segmentadas en entrenamiento, validación y prueba. Se realizará un ajuste iterativo de hiperparámetros, monitoreando métricas para asegurar la convergencia y generalización.

Los recursos incluyen hardware de alta capacidad, bibliotecas de deep learning compatibles con PyTorch, y bases de datos públicas y privadas para el entrenamiento. Las etapas críticas del proyecto comprenden la correcta preparación y etiquetado de datos, implementación y calibración de modelos, ajuste fino de hiperparámetros, evaluación rigurosa y comparación de resultados, asegurando así la validez técnica y práctica del desarrollo.

*A mi querido gato,
que no hace nada por nadie,
pero incluso así,
se ganó un espacio en esta sección.*

Tabla de Contenido

1. Introducción	1
1.1. Objetivo General	1
1.2. Objetivos Específicos	1
1.3. Alcances	1
2. Antecedentes	3
2.1. Estado del arte en la identificación de fallas en correas transportadoras . . .	3
2.1.1. Fallas en correas transportadoras	4
2.2. Arquitectura Redes Neuronales Convolucionales (CNN) y Transfer Learning (TL)	5
2.3. Arquitectura Encoder-Decoder y Destilación de Conocimiento en Deep Learning	5
2.4. YOLO (You Only Look Once) y SSD (Single Shot Multibox Detector)	6
2.4.1. Arquitecturas	6
2.4.2. Hiperparámetros	6
2.5. DETR (DEtection TRansformer) y DINO	6
2.5.1. Arquitecturas	6
2.5.2. Hiperparámetros	7
2.6. Métricas	7
2.6.1. Precisión, Exhaustividad y F-Score	7
2.6.2. IoU y Confianza	8
2.6.3. AP y mAP	8
2.6.4. Matriz de Confusión	8
3. Metodología	9
3.1. Identificación de fallas	9
3.2. Base de datos	9
3.2.1. Recopilación	9
3.2.2. Etiquetado	9
3.2.3. Partición	9
4. Resultados y Discusión	10
4.1. Métricas de entrenamiento	10
4.2. Métricas de Validación	10
4.3. Pruebas y detección de fallas	10
4.4. Conclusiones	10

Índice de Tablas

Índice de Ilustraciones

Capítulo 1

Introducción

Las correas transportadoras son esenciales en minería e industria para trasladar grandes volúmenes de material, pero están expuestas a desgaste que puede causar fallas y detenciones no programadas. La detección temprana es crucial para evitar pérdidas. Frente a las limitaciones de métodos manuales, los modelos de inteligencia artificial permiten una detección precisa y en tiempo real. Ante esto, la visión computacional se posiciona como herramienta clave para el mantenimiento predictivo [?].

1.1. Objetivo General

Implementar y evaluar algoritmos de detección de objetos, basados en inteligencia artificial, para la identificación automática de fallas en correas transportadoras.

1.2. Objetivos Específicos

Para lograr el objetivo general en este futuro trabajo de memoria de título, se propone cumplir con los siguientes objetivos específicos:

1. Implementar modelos de detección de objetos basados en redes convolucionales, tales como YOLO (You Only Look Once) y sus variantes, y SSD (Single Shot Multibox Detector).
2. Implementar modelos de detección de objetos basados en redes neuronales artificiales con arquitectura tipo transformer, tales como DETR (DEtection TRansformer) y DINO.
3. Entrenar algoritmos de detección utilizando bases de datos con registros de fallas en correas transportadoras.
4. Comparar el desempeño de los modelos en la detección de distintos tipos de fallas mediante el uso de métricas de evaluación cuantitativas.

1.3. Alcances

- El entrenamiento de los algoritmos de detección se realizará exclusivamente con bases de datos públicas disponibles en la web que contengan registros de fallas en correas transportadoras.

- Considerar el uso de datos sin etiquetar, los cuales serán procesados mediante estrategias de etiquetado manual o mediante técnicas no supervisadas y/o auto-supervisadas, según su aplicabilidad.
- Evaluar el rendimiento de los modelos seleccionados (YOLO, SSD, DETR y DINO) en la detección y clasificación de fallas, utilizando una misma base de datos con partición en conjuntos de entrenamiento, validación y prueba. Posteriormente se evaluarán utilizando métricas estándar de evaluación.

Capítulo 2

Antecedentes

2.1. Estado del arte en la identificación de fallas en correas transportadoras

El aprendizaje profundo (Deep Learning) se ha consolidado como una herramienta clave en el *procesamiento de imágenes, visión computacional y reconocimiento de patrones*, debido a su capacidad para aprender representaciones de alto nivel desde datos masivos. A través de enfoques supervisados, no supervisados y semi-supervisados, estos algoritmos han superado a los métodos tradicionales, particularmente en tareas de clasificación y segmentación. El aprendizaje por transferencia (transfer learning) ha sido especialmente útil en entornos con escasez de datos etiquetados, permitiendo la reutilización de modelos preentrenados para mejorar el rendimiento en nuevas tareas [?].

La detección de fallas en correas transportadoras se aborda como un problema de detección de objetos mediante aprendizaje supervisado. Existen dos enfoques principales: los modelos de dos etapas, como la familia R-CNN (red neuronal convolucional basada en regiones), que emplean redes de propuestas regionales seguidas de refinamiento, y los modelos de una etapa, como YOLO y SSD, que realizan predicciones por regresión directa, optimizados para aplicaciones en tiempo real [?].

La detección de objetos ha sido uno de los problemas centrales en visión por computadora, tradicionalmente abordado mediante arquitecturas basadas en redes neuronales convolucionales (CNN). Estos modelos dominaron el campo durante más de una década, impulsando desarrollos significativos en precisión y eficiencia. Sin embargo, alcanzar un balance óptimo entre velocidad y exactitud ha requerido explorar estructuras más allá del marco convencional de las CNN. Los modelos basados en transformers, originalmente desarrollados para procesamiento de lenguaje natural (Natural Language Processing), han demostrado ser altamente efectivos al capturar relaciones espaciales globales en imágenes, lo que los convierte en una propuesta a considerar para la implementación de nuevos modelos de detección de objetos [?].

Una memoria de título desarrollada en la Universidad de Chile [?] implementa visión computacional y técnicas de aprendizaje profundo (Deep Learning) para la detección temprana de fallas en correas transportadoras, utilizando una de las versiones del modelo YOLO (You Only Look Once). El estudio describe detalladamente la implementación y calibración del modelo, además de proporcionar información técnica sobre redes neuronales convolucio-

nales, métricas de evaluación, pruebas experimentales y resultados ilustrativos.

2.1.1. Fallas en correas transportadoras

Las correas transportadoras operan en condiciones que las exponen a diversos tipos de daños, los cuales pueden generar costosos tiempos de inactividad. Para cada condición de falla, se han revisado exhaustivamente sus tipos y causas, así como los métodos adecuados para su mitigación, contribuyendo a mejorar la confiabilidad del sistema [?].

Entre las fallas más comunes en correas transportadoras se identifican el **daño por impacto**, que puede provocar **perforaciones o roturas locales**; la **delaminación**, generada por esfuerzos cíclicos y fatiga; y la **desalineación de la banda**, que causa **desgaste anómalo en los bordes**. Además, se reporta **desgaste abrasivo** en la cubierta superior por efecto de partículas duras, **rotura de cables de acero** en correas reforzadas, y **cortes longitudinales y transversales**, todos los cuales afectan directamente la vida útil y seguridad operativa del sistema.



Figura 2.1.1: Tipos de falla comunes en correas transportadoras, imágenes adaptadas de [?].

2.2. Arquitectura Redes Neuronales Convolucionales (CNN) y Transfer Learning (TL)

La detección de objetos en visión computacional consiste en identificar automáticamente instancias presentes en una imagen o secuencia, localizándolas mediante cajas delimitadoras y clasificándolas correctamente. Esta tarea combina elementos de clasificación, localización y, en algunos casos, segmentación [?].

Los modelos de detección de objetos que solamente realizan una captura (single shot), poseen una arquitectura basada en redes neuronales convolucionales (CNN) y sus variantes, como por ejemplo R-CNN (CNN basado en la región) o Faster R-CNN (R-CNN más rapido).

Las redes neuronales convolucionales (CNN) están inspiradas en el funcionamiento de la corteza visual del cerebro humano, emulando la capacidad de identificar objetos mediante características como bordes, formas y colores. Estas redes operan sobre imágenes 2D o 3D y se estructuran típicamente en tres etapas: capas de convolución, capas de reducción (pooling) y capas densas. Este enfoque permite que las CNN reconozcan patrones visuales de forma progresiva, desde rasgos simples hasta representaciones complejas [?].

El aprendizaje por transferencia (transfer-learning) es una metodología eficaz cuando la disponibilidad de datos etiquetados es limitada, ya que aprovecha el conocimiento previamente aprendido por un modelo entrenado en un dominio específico para aplicarlo a una tarea distinta, lo que permite acelerar el proceso de entrenamiento y mejorar el desempeño del modelo [?].

2.3. Arquitectura Encoder-Decoder y Destilación de Conocimiento en Deep Learning

Los modelos encoder-decoder basados en transformers, como DETR y DINO, utilizan un codificador que transforma la imagen en embeddings (vectores matemáticos) mediante auto-atención, y un decodificador que cruza estas representaciones con un conjunto fijo de consultas para predecir directamente clases y localización de objetos.

Debido a la complejidad de estos mecanismos de atención, han surgido métodos de explicabilidad que permiten visualizar la relevancia de cada token de entrada en la inferencia. Entre ellos, se propone un enfoque general aplicable a arquitecturas bi-modales y encoder-decoder, que genera mapas de atención interpretables. Estas capacidades son especialmente útiles en detección basada en transformers, donde también se integran estrategias como la destilación de conocimiento y el aprendizaje auto-supervisado para mejorar el rendimiento con datos limitados [?].

La destilación de conocimiento (knowledge-distillation) es una estrategia de aprendizaje profundo que permite transferir la capacidad representacional de modelos visuales de gran escala (teacher) hacia arquitecturas más livianas y eficientes (student), reduciendo significativamente el costo computacional durante la inferencia. En el contexto de tareas como la detección de objetos, esta técnica ha demostrado ser efectiva al extraer y condensar el

conocimiento de modelos preentrenados en clasificación [?].

2.4. YOLO (You Only Look Once) y SSD (Single Shot Multibox Detector)

2.4.1. Arquitecturas

YOLO y SSD son modelos de detección de objetos de tipo single-shot, es decir, realizan la detección y clasificación en una única pasada de la red. Ambos están basados en redes neuronales convolucionales (CNN).

YOLO (You Only Look Once) es un enfoque de detección de objetos de una sola etapa que destaca por su alta velocidad y eficiencia, al predecir directamente las clases y ubicaciones de objetos en una sola pasada por la red. A diferencia de métodos de dos etapas como R-CNN o Faster R-CNN, YOLO evita la generación de propuestas de regiones, lo que lo hace apto para aplicaciones en tiempo real. Su arquitectura unificada lo convierte en una opción balanceada entre precisión y velocidad [?].

SSD (Single Shot Multibox Detector) es otro enfoque en la detección de objetos, caracterizado por su capacidad de realizar clasificación y regresión de cajas delimitadoras en una única pasada de la red, sin requerir etapas de propuesta de regiones. SSD utiliza múltiples mapas de características de diferentes escalas para detectar objetos de diversos tamaños, lo que mejora la precisión especialmente en objetos pequeños [?].

2.4.2. Hiperparámetros

Los hiperparámetros son valores que controlan el proceso de aprendizaje y condicionan los parámetros internos que el modelo ajusta durante el entrenamiento. Se denominan así por encontrarse en un nivel superior, ya que no forman parte del modelo aprendido, sino que guían su optimización. Al finalizar el entrenamiento, el modelo resultante contiene únicamente los parámetros ajustados, mientras que los hiperparámetros utilizados permanecen externos a dicha estructura [?].

El ajuste de hiperparámetros en los modelos de detección de objetos basados en redes neuronales convolucionales, es un proceso iterativo el cual está destinado a optimizar las métricas de evaluación utilizadas en visión computacional [?].

2.5. DETR (DEtection TRansformer) y DINO

2.5.1. Arquitecturas

DETR y DINO son modelos de detección de objetos basados en la arquitectura de transformers, originalmente desarrollada para procesamiento de lenguaje natural, pero adaptada para visión por computadora.

DETR (DEtection TRansformer) es un modelo de aprendizaje profundo (deep-learning), compuesta por tres elementos principales: un backbone convolucional (CNN backbone) que

extrae las representaciones visuales, un transformador encoder-decoder (encoder-decoder transformer) que modela relaciones globales en la imagen, y una red neuronal completamente conectada (feed forward network, FFN) que realiza las predicciones finales. DETR no requiere componentes manuales ni estructuras complejas, lo que permite su implementación en frameworks de aprendizaje profundo estándar con pocas líneas de código [?].

DINO es un modelo basado en DETR que incluye un backbone, un encoder y decoder multi-capas de Transformer, y múltiples cabezas de predicción (prediction heads). Emplea extractores de características multiescala que se procesan con embeddings posicionales (positional embeddings) en el encoder. Su innovación principal, respecto a DETR, es la selección mixta de queries (solicitudes) para inicializar anclas posicionales (positional anchors) en el decoder, mientras que las queries de contenido (content queries) permanecen aprendibles. Utiliza atención deformable (deformable attention) para actualizar características capa a capa y cuenta con una rama de desruido (denoising) con entrenamiento contrastivo, mejorando la gestión de muestras difíciles [?].

2.5.2. Hiperparámetros

En el modelo DETR, los hiperparámetros incluyen configuraciones específicas del número de *layers* (capas) en la arquitectura, tasas de *regularization* (regularización), tipo de *optimizer* (optimizador) y esquemas de *data augmentation* (aumento de datos) [?].

En el modelo DINO, los hiperparámetros comparten similitudes con DETR, incluyendo el uso del optimizador AdamW con regularización por decaimiento de peso (weight decay) y ajustes en la tasa de aprendizaje mediante un programador dinámico (learning rate scheduler). Además, DINO incorpora un conjunto fijo y ampliado de consultas para el decoder (decoder queries), optimizando el equilibrio entre desempeño y costo computacional durante el entrenamiento [?].

2.6. Métricas

Con el fin de validar la implementación de los modelos de detección de objetos para la clasificación de fallas, se emplean métricas cuantitativas estándar en visión por computador. El uso de estas métricas otorgan las herramientas esenciales para evaluar críticamente y de forma fiable los modelos implementados [?].

2.6.1. Precisión, Exhaustividad y F-Score

La **precisión** (*precision*) mide la proporción de verdaderos positivos entre todas las predicciones positivas. El **recall** o *exhaustividad* mide la proporción de verdaderos positivos detectados sobre los positivos reales.

$$\text{Precision} = \frac{TP}{TP + FP} \quad \text{Recall} = \frac{TP}{TP + FN}$$

Tabla 2.6.1: Definiciones generales *Machine Learning* [?]]

Abreviación	Significado
T	Total
P	Positivos
N	Negativos
TP	Verdaderos Positivos
TN	Verdaderos Negativos
FP	Falsos Negativos
n	Número de Clases

El **F-Score** (F_β) es la media ponderada entre precisión y recall, ajustada por el parámetro β . Un caso particular es el **F1-Score** (F_1), donde $\beta = 1$.

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}} \quad F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

2.6.2. IoU y Confianza

El **IoU** (**Intersection over Union**) evalúa el solapamiento entre la predicción y la verdad de terreno:

$$\text{IoU} = \frac{\text{Área de Intersección}}{\text{Área de Unión}}$$

La **confianza** asigna una probabilidad a la predicción, y el **umbral de confianza** define el valor mínimo para aceptar una detección.

2.6.3. AP y mAP

La **Average Precision** (**AP**) corresponde al área bajo la curva precisión-recall para una clase. El **mean Average Precision** (**mAP**) es el promedio del AP para todas las clases.

El **mAP@50** utiliza un umbral IoU fijo de 0,5. **mAP@50-95** promedia el AP en umbrales de IoU entre 0,5 y 0,95 (paso de 0,05), reflejando un criterio más exigente y robusto.

2.6.4. Matriz de Confusión

Representa los aciertos y errores del clasificador mediante los conteos de verdaderos/falsos positivos y negativos por clase, permitiendo un análisis detallado del comportamiento del modelo.

Capítulo 3

Metodología

3.1. Identificación de fallas

3.2. Base de datos

3.2.1. Recopilación

3.2.2. Etiquetado

3.2.3. Partición

Capítulo 4

Resultados y Discusión

- 4.1. Métricas de entrenamiento
- 4.2. Métricas de Validación
- 4.3. Pruebas y detección de fallas
- 4.4. Conclusiones

Bibliografía

- [1] Zhang, M., Shi, H., Zhang, Y., Yu, Y., y Zhou, M., “Deep learning-based damage detection of mining conveyor belt”, *Measurement: Journal of the International Measurement Confederation*, vol. 175, p. 109130, 2021, [doi:10.1016/j.measurement.2021.109130](https://doi.org/10.1016/j.measurement.2021.109130).
- [2] Gupta, J., Pathak, S., y Kumar, G., “Deep Learning (CNN) and Transfer Learning: A Review”, *Journal of Physics: Conference Series*, vol. 2273, no. 1, p. 012029, 2022, [doi:10.1088/1742-6596/2273/1/012029](https://doi.org/10.1088/1742-6596/2273/1/012029).
- [3] Arkin, E., Yadikar, N., Xu, X., Aysa, A., y Ubul, K., “A survey: object detection methods from CNN to transformer”, *Multimedia Tools and Applications*, vol. 82, no. 14, pp. 21353–21383, 2023, [doi:10.1007/s11042-022-13801-3](https://doi.org/10.1007/s11042-022-13801-3).
- [4] Fuente, V. B. A. D. L., “Detección temprana de fallas en cintas transportadoras mediante visión computacional y deep learning”, memoria para optar al título de ingeniera civil mecánica, Universidad de Chile, Santiago, Chile, 2024. Acceso abierto.
- [5] Khanna, A., Singh, B., y Kumar, S., “Types and causes of damage to the conveyor belt – Review, classification and mutual relations”, *Engineering Failure Analysis*, vol. 141, p. 106553, 2022, [doi:10.1016/j.engfailanal.2022.106553](https://doi.org/10.1016/j.engfailanal.2022.106553).
- [6] Kaur, J. y Singh, W., “Tools, techniques, datasets and application areas for object detection in an image: a review”, *Multimedia Tools and Applications*, vol. 81, no. 27, pp. 38297–38351, 2022, [doi:10.1007/s11042-022-13153-y](https://doi.org/10.1007/s11042-022-13153-y).
- [7] Badillo, F. L., Hernández, C. A. R., Narváez, B. M., y Trillos, Y. E. A., “Redes neuronales convolucionales: un modelo de Deep Learning en imágenes diagnósticas. Revisión de tema”, *Revista Colombiana de Radiología*, 2023, [doi:10.53903/01212095.161](https://doi.org/10.53903/01212095.161).
- [8] Iman, M., Arabnia, H. R., y Rasheed, K., “A review of deep transfer learning and recent advancements”, *Technologies*, vol. 11, no. 2, p. 40, 2023, [doi:10.3390/technologies11020040](https://doi.org/10.3390/technologies11020040).
- [9] Chefer, H., Gur, S., y Wolf, L., “Generic Attention-model Explainability for Interpreting Bi-Modal and Encoder-Decoder Transformers”, en *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, p. 397–406, IEEE, 2021.
- [10] Li, G., Wang, W., Li, X., Li, Z., Yang, J., Dai, J., Qiao, Y., y Zhang, S., “Distilling Knowledge from Large-Scale Image Models for Object Detection”, en *Proceedings of the European Conference on Computer Vision (ECCV)*, p. 11200, 2024, https://www.ecva.net/papers/eccv_2024/papers_ECCV/papers/11200.pdf.
- [11] Terven, J., Córdova-Esparza, D., y Romero-González, J., “A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS”, *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1716, 2023, [doi:](https://doi.org/10.1109/mlke.2023.3288888)

10.3390/make5040083.

- [12] Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C., y Berg, A. C., “SSD: Single Shot MultiBox Detector”, en Computer Vision – ECCV 2016, Lecture Notes in Computer Science, Vol. 9905, pp. 21–37, Springer International Publishing, 2016, doi:10.1007/978-3-319-46448-0_2.
- [13] Nyuytiymbiy, K., “Parameters and Hyperparameters in Machine Learning and Deep Learning”, Towards Data Science, December 2020, <https://towardsdatascience.com/parameters-and-hyperparameters-aa609601a9ac>.
- [14] Ultralytics, “Ultralytics YOLO Hyperparameter Tuning Guide”, 2025, <https://docs.ultralytics.com/guides/hyperparameter-tuning/>.
- [15] Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., y Zagoruyko, S., “End-to-End Object Detection with Transformers”, en Proceedings of the European Conference on Computer Vision (ECCV), p. 213–229, 2020, doi:10.1007/978-3-030-58452-8_13.
- [16] Zhang, H., Li, F., Liu, S., Zhang, L., Su, H., Zhu, J., Ni, L. M., y Shum, H.-Y., “DINO: DETR with Improved DeNoising Anchor Boxes for End-to-End Object Detection”. arXiv preprint arXiv:2203.03605, 2022. Accepted at ICLR 2023.
- [17] Schlosser, T., Friedrich, M., Meyer, T., y Kowerko, D., “A Consolidated Overview of Evaluation and Performance Metrics for Machine Learning and Computer Vision”, August 2024, https://www.researchgate.net/publication/379982431_A_Consolidated_Overview_of_Evaluation_and_Performance_Metrics_for_Machine_Learning_and_Computer_Vision. Accessed manuscript, unpublished.

Anexos